AiCon
全球人工智能与机器学习技术大会

机器学习加持下的
时序类数据异常智能监控

刘彪
高级工程师@腾讯

主办方 Geekbang 极客邦科技 InfoQ

极客时间

重拾极客精神·提升技术认知

下载极客时间App

获取有声IT新闻、技术产品专栏，每日更新

扫一扫下载极客时间App

人工智能基础课

“通俗易懂的人工智能入门课”

王天一
博士 副教授

扫一扫，免费试读

AI技术内参

你的360度人工智能信息助理

洪亮劼
Etsy 数据科学主管

扫一扫，免费试读

AI 前线

关注落地技术，探寻AI应用场景

- 14万AI领域垂直用户
- 8000+社群技术交流人员，不乏行业内顶级技术专家
- 每周一节干货技术分享课
- AI一线领军人物的访谈
- AI大会的专家干货演讲整理
- 《AI前线》月刊
- AI技能图谱
- 线下沙龙

扫码关注带你涨姿势

Geekbang. 极客邦科技 | InfoQ

ArchSummit 全球架构师峰会

2018 · 深圳站

从2012年开始算起，InfoQ已经举办了9场ArchSummit全球架构师峰会，有来自Microsoft、Google、Facebook、Twitter、LinkedIn、阿里巴巴、腾讯、百度等技术专家分享过他们的实践经验，至今累计已经为中国技术人奉上了近千场精彩演讲。

限时7折报名中，名额有限，速速报名吧！

2012.08.10-12 深圳站

2018.07.06-09 深圳站

会议：07.06-07.07

培训：07.08-07.09

TABLE OF CONTENTES

监控系统：Monitor

250万属性

20人

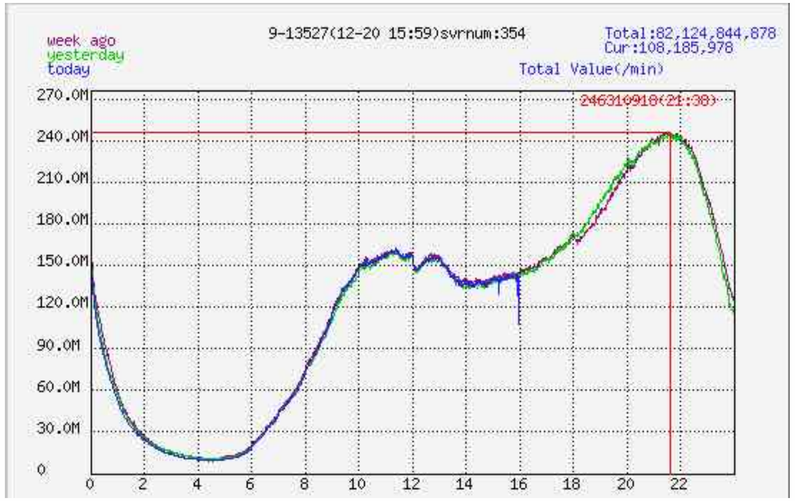

Monitor的问题

运维成本高

4万/天，200条/人

准确率极低、6%

理想中的监控

一个零

- 触发条件“0”维护

两个九

- 准确率：90%
- 召回率：90%

TABLE OF CONTENTES

GBDT初探

初探：

第几轮	样本	正类	负类	正类占比	召回率	准确率	精确率	**11个视图，8024个属性**	备注
第一轮	1383	541	842	39%	81%	96%	86%		未达预期
第二轮	5707	5285	422	92%	96%	96%	98%	04月30日：13%异常率	过多异常
第三轮	20298	5285	15013	26%	99%	92%	96%	04月30日：0%异常率 05月10日：0%异常率 04月02日：0%异常率	无异常

https://pan.baidu.com/s/1jIDwZTO#list/path=%2F&parentPath=%2F

GBDT“失败”总结

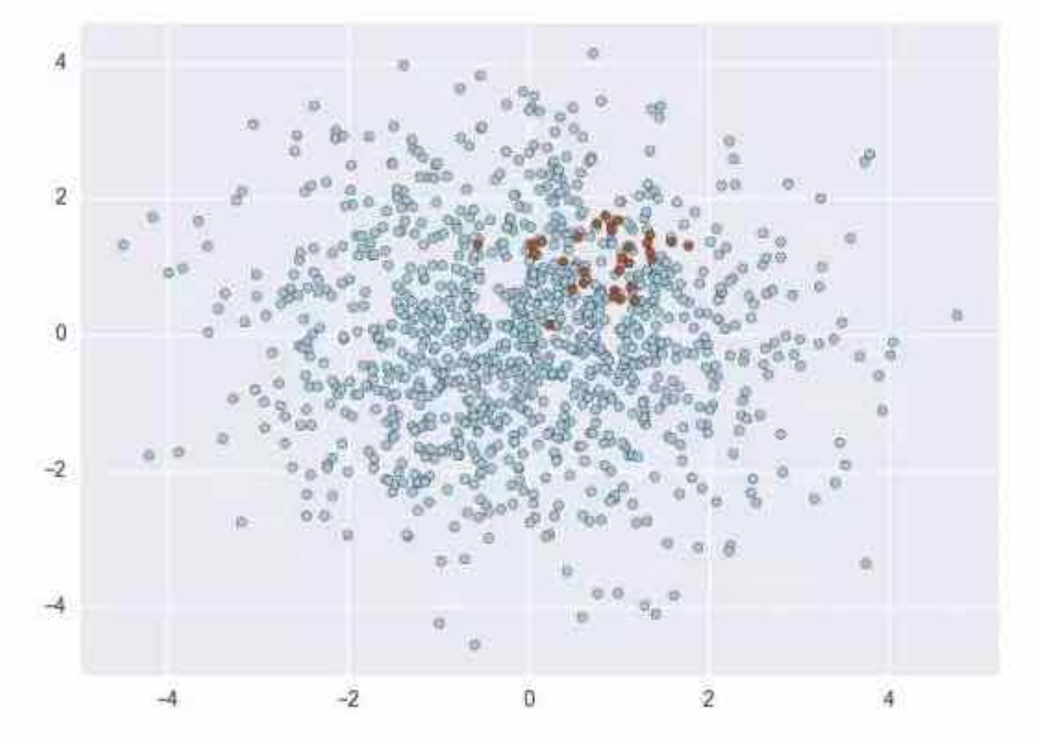

原因分析

- 样本不全面，11/8000
- 正负样本不均衡，比例为10000：1

结论

- 监控行业负样本稀疏
- 负样本获取困难

解决方案

✓ 过滤掉大量正常样本

1. 统计判别法
2. 无监督

统计判别法

准则	显著性检测	公式	优缺点
Pauta	正态分布	$\|x_i-ul\| > 3 * \sigma$	使用简单，样本较少时误差比较大
Chauvenet	正态分布	$\|x_i-ul\| > Z_c * \sigma$	$Z_c < 3$且与n相关，比Pauta更加准确，可用于n< 10的粗大判定
Grubbs	正态或接近正态	$\|x_i-ul\| > T * \sigma$	T与n和概率α 有关，判断标准更加严格，在n=20-100时，效果较好
Dixon	不需要	相对复杂	应用于同组数据的一致性检验，但计算相对复杂
T-Test	不需要	$\|x_i-ul\|>K*\sigma$ 或者 $\|x_i-ul\|>K*\sigma$	与Dixon类似

正态性检测

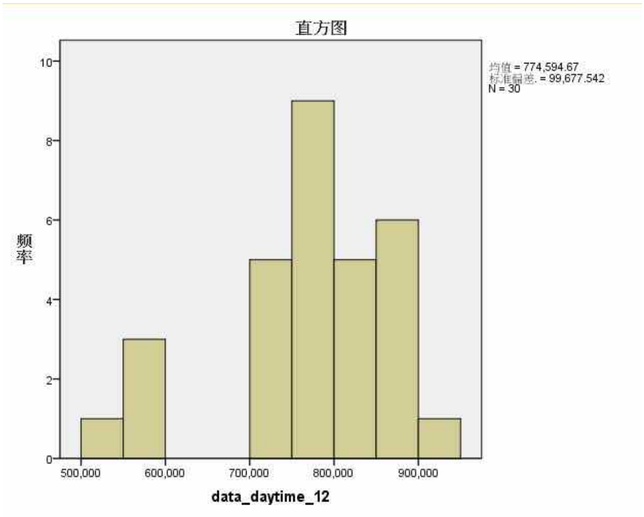

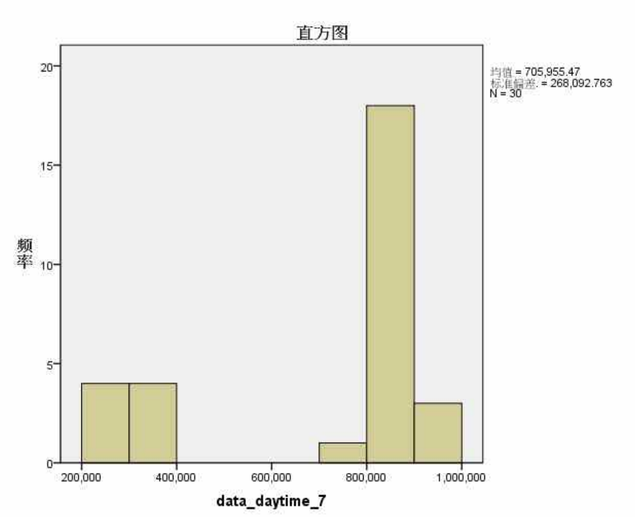

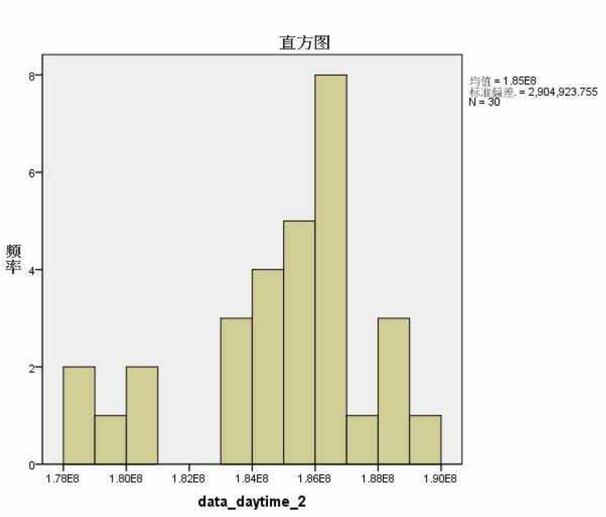

定性结果：同一时刻的上报值，长时间窗口看趋于正态分布

统计判别法：Grubbs

```
def calculate_statistic(self, value_list):
    return list(pandas.DataFrame(value_list).describe()[0].values[1:])

def grubbs_predict(self, check_value, ref_value_list):
    t_index = self.index
    ref_desc = self.calculate_statistic(ref_value_list)
    if abs(check_value - ref_desc[0]) > t_index * ref_desc[1]:
        return -1
    else:
        return 1
```

算法

1. 值：当前时刻点
2. 参考值：前后N分钟的环比、同比、周同比值
3. 均值、标准差
4. $|x_i-u|$ 与 $Z * \sigma$比大小
5. 异常：$|x_i-u| > Z * \sigma$

Grubbs算法结果

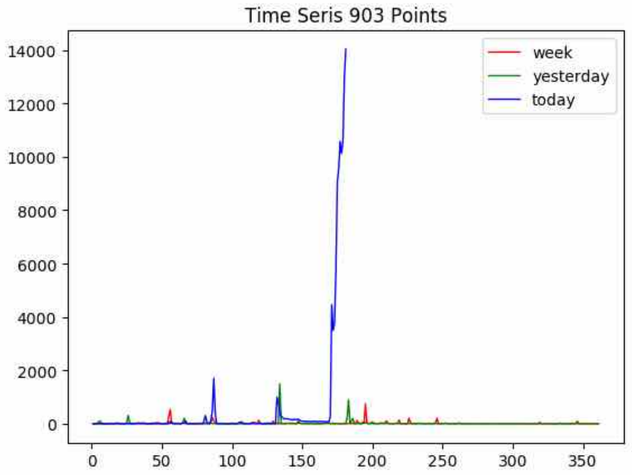
Time Seris 903 Points
week
yesterday
today
14000
12000
10000
8000
6000
4000
2000
0
0
50
100
150
200
250
300
350

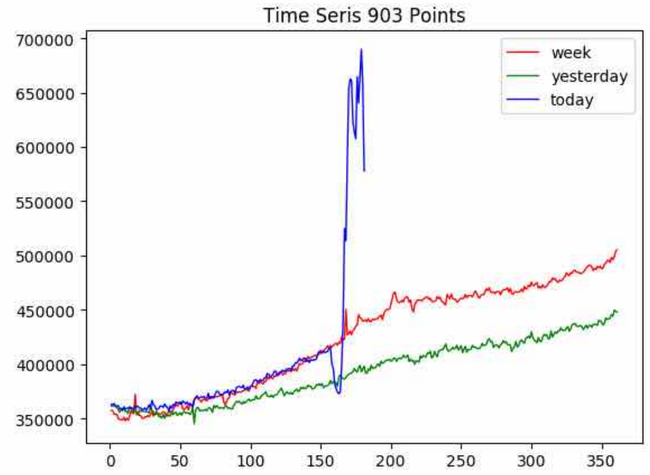
Time Seris 903 Points
week
yesterday
today
700000
650000
600000
550000
500000
450000
400000
350000
0
50
100
150
200
250
300
350

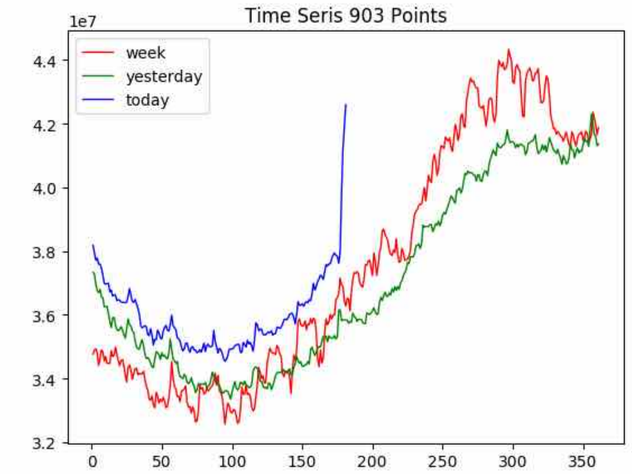
Time Seris 903 Points
1e7
week
yesterday
today
4.4
4.2
4.0
3.8
3.6
3.4
3.2
0
50
100
150
200
250
300
350

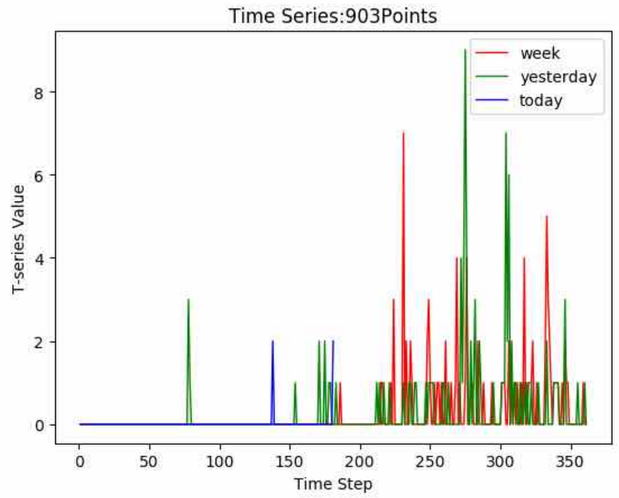
Time Series:903Points
week
yesterday
today
T-series Value
8
6
4
2
0
0
50
100
150
200
250
300
350
Time Step

Grubbs分析优化

第一轮	总样本	3h_3	1h_3	3h_or_1h_3
正样本	19	17	17	17
负样本	208	153	75	158
准确率		74.9%	40.5%	**77.1%**
召回率		73.6%	36.1%	**76.0%**
8000正样本误召回率		0.0%	NA	**0%**

第二轮	总样本	1h_2	1h_2.5	1h_3	1h_3.5	3h_2	3h_2.5	3h_3	3h_3.5	1h_or_3h_2	耗时
正样本											
负样本	1328	991	725	542	465	1122	1038	889	690	1147	
准确率											
召回率		74.6%	54.6%	40.8%	35.0%	84.5%	78.2%	66.9%	52.0%	**86.4%**	4ms/个
8000正样本误召回率		NA	NA	NA	NA	2.0%	0.4%	0.0%	0.0%	**<2.0%**	

优化点：1，$|x_i - ul|$ 与 $Z * \sigma$，Z调整；2，Window大小

无监督算法

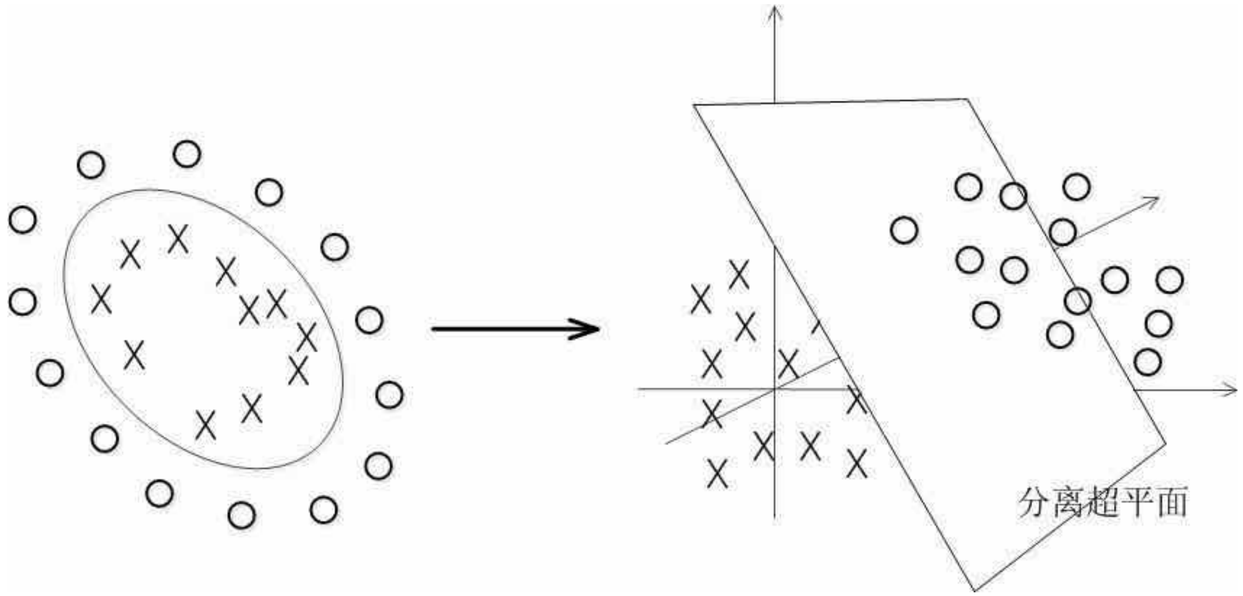
分离超平面

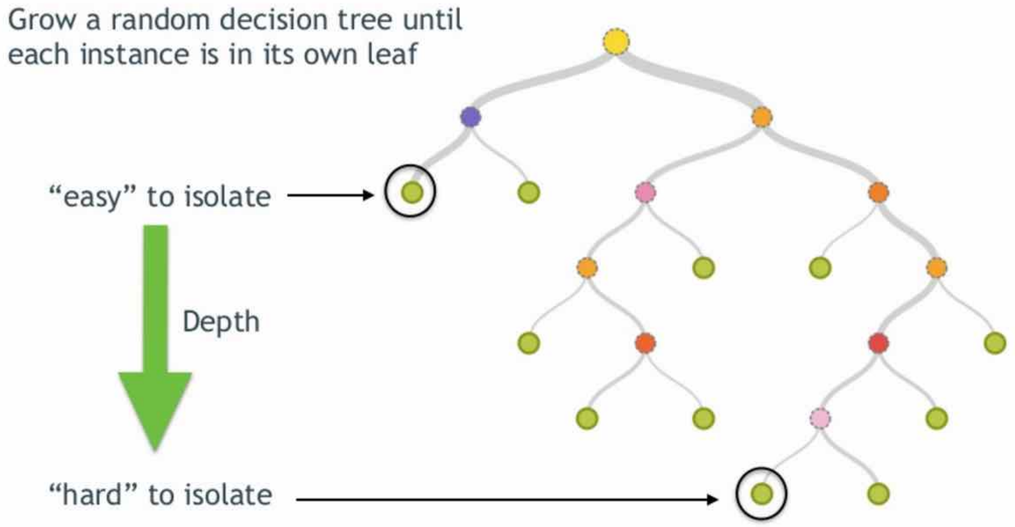
Grow a random decision tree until
each instance is in its own leaf
“easy” to isolate
Depth
“hard” to isolate

无监督算法：Isolation Forest

```
def if_predict(self, sample_features):
    clf = IsolationForest(n_estimators=3,max_samples='auto',contamination=0.15)
    # clf = IsolationForest()
    clf.fit(sample_features)
    y_pred_test = clf.predict(sample_features)
    # print y result
    return y_pred_test[-1]
```

Isolation Forest算法结果

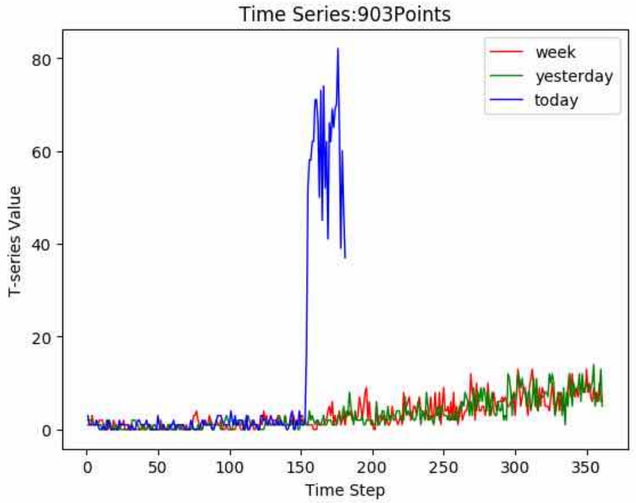

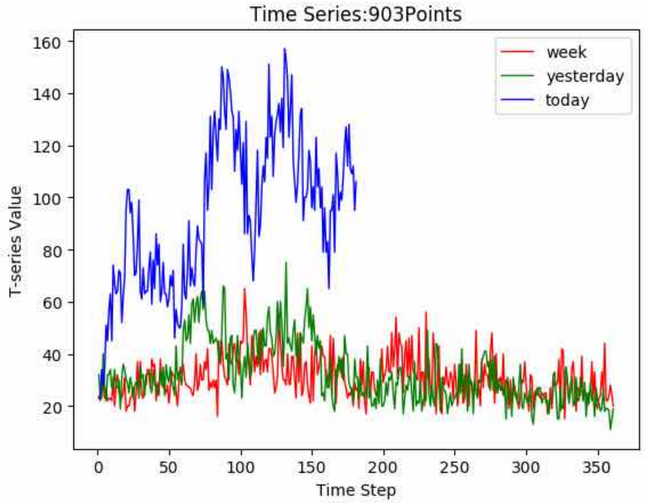

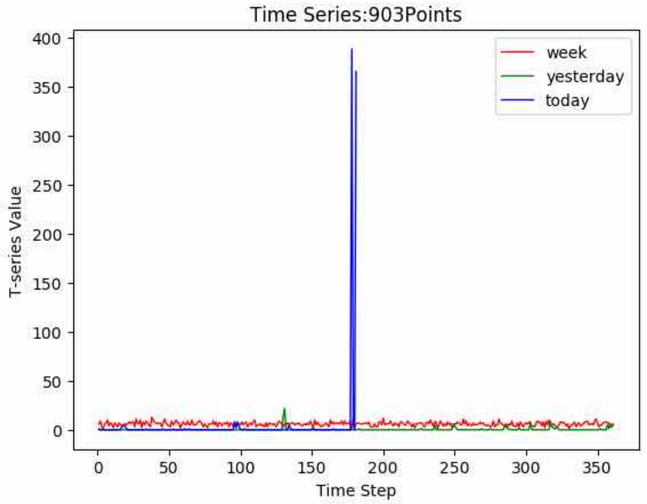

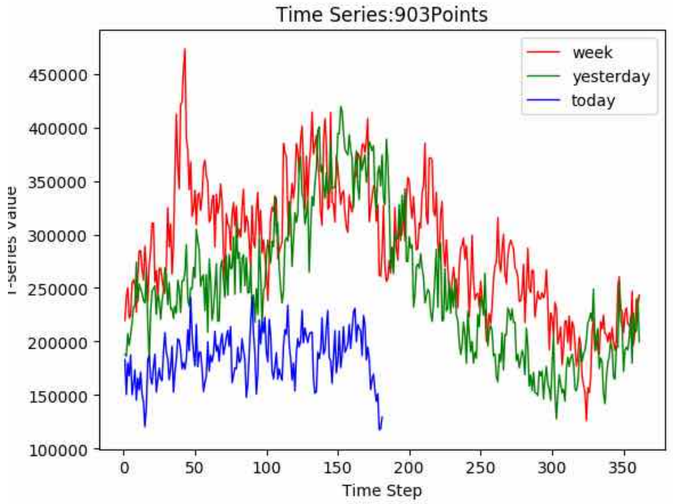

Isolation Forest分析优化

第二轮	总样本	1h_2	1h_2.5	1h_3	1h_3.5	3h_2	3h_2.5	3h_3	3h_3.5	1h_or_3h_2	耗时
正样本	8000										
负样本	1328	991	725	542	465	1122	1038	889	690	1147	
准确率											
召回率		74.6%	54.6%	40.8%	35.0%	84.5%	78.2%	66.9%	52.0%	**86.4%**	**4ms/个**
8000正样本误召回率		NA	NA	NA	NA	2.0%	0.4%	0.0%	0.0%	**<2.0%**	

第二轮	总样本	Default	n_estimators=3 max_samples='auto' contamination=0.15
正样本	8000		
负样本	1328	1287	1192
准确率			
召回率		96.9%	**89.8%**
8000正样本误召回率		5%	**11.6%**
耗时		243ms/个	**10ms/个**

优化：参数调整，n_estimators=3，max_samples='auto'，contamination=0.15

Grubbs & Isolation Forest

	总样本	3h_2	3h_3	1h_or_3h_2	n_estimators=3 max_samples='auto' contamination=0.15	3h_2 or n_estimators=3 max_samples='auto' contamination=0.15
正样本	8000					
负样本	1328	1122	889	1147	1192	1252
准确率						
召回率		84.5%	66.9%	86.4%	89.8%	**95%**
8000正样本误召回率		2.0%	0.0%	<2.0%	11.6%	**7%**
耗时		4ms/个	4ms/个	4ms/个	10ms/个	

优化：算法整合

有监督算法：

```
def gbdt_train(self,train):
    # Get train/test set random
    sample_random = random.sample(train, len(train))
    trainset = np.array(sample_random[0:int(len(sample_random)*0.9)])
    testset = np.array(sample_random[int(len(sample_random)*0.9):])
    y = trainset[:, -1]
    x = trainset[:, (0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19, 20, 21, 22, 23, 24, 25, 26, 27, 28, 29,30,31)]
    y_test = testset[:, -1]
    x_test = testset[:, (0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19, 20, 21, 22, 23, 24, 25, 26, 27, 28, 29,30,31)]
    # Trainning
    grd = GradientBoostingClassifier(n_estimators=300, max_depth=10, learning_rate=0.05)
    grd.fit(x, y)
    preds = grd.predict_proba(x_test)[:, 1]
    gbdt_auc = roc_auc_score(y_test, preds)
    model_name = "gbdt_model"+ "_" + time.strftime('%Y-%m-%d',time.localtime(time.time()))
    pickle.dump(grd, open(model_name, "wb"))
    print "AUC:",gbdt_auc
                    标记为负样本
def gbdt_predict(self,x_test):
    testset = np.array([x_test])  #注意此处中括号，默认样本位多样本数据
    x_test = testset[:,(0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19, 20, 21, 22, 23, 24, 25, 26, 27, 28, 29,30,31)]
    loaded_model = pickle.load(open("./gbdt_model_2018-01-03", "rb"))
    preds_new = loaded_model.predict_proba(x_test)[:, 1]
    return preds_new[0]
```

GBDT解决的问题

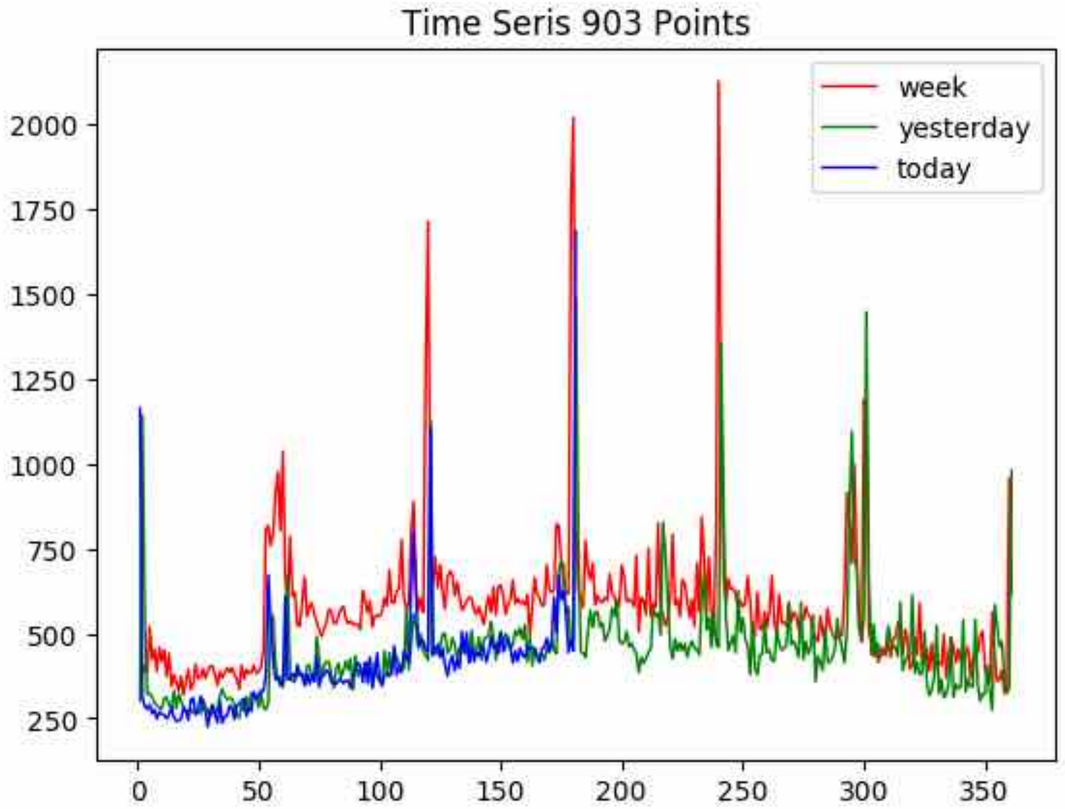
Time Seris 903 Points
week
yesterday
today
2000
1750
1500
1250
1000
750
500
250
0
50
100
150
200
250
300
350

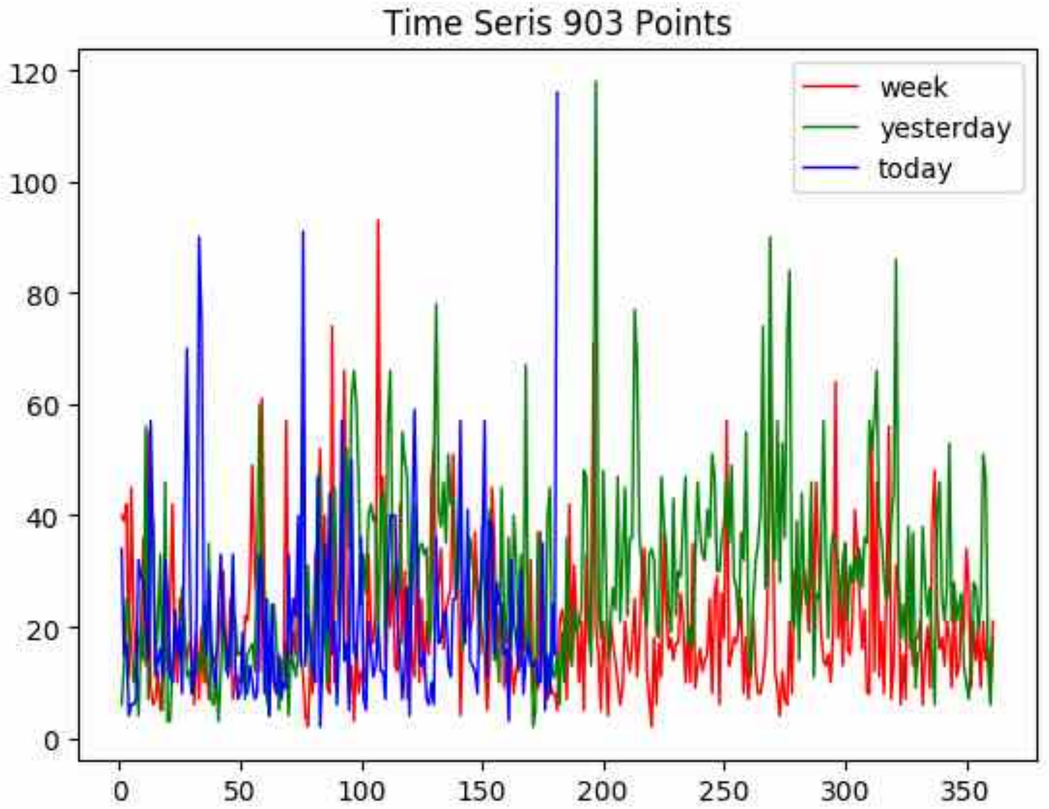
Time Seris 903 Points
week
yesterday
today
120
100
80
60
40
20
0
0
50
100
150
200
250
300
350

GBDT分析优化

第一轮	总样本	GBDT
正样本	404	323
负样本	96	64
召回率	NA	**66.6%**
正确率	NA	**77.4%**

第二轮	总样本	GBDT	GBDT_OPT
正样本	2029	1980	1991
负样本	5464	5350	5410
召回率	NA	**98%**	**99%**
正确率	NA	**97%**	**98%**

优化：1，新增样本；2，新增特征

TABLE OF CONTENTES

算法方案

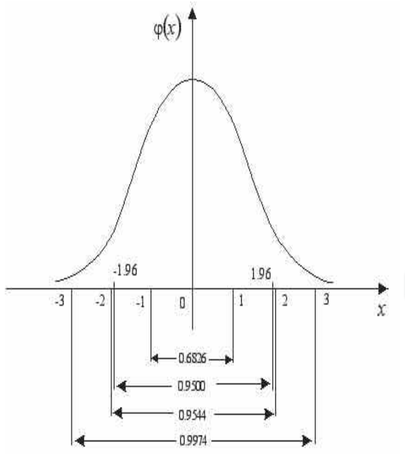

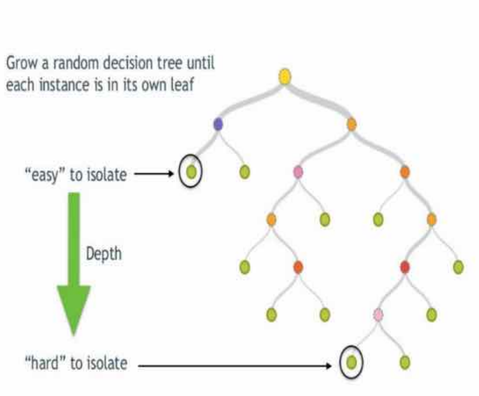

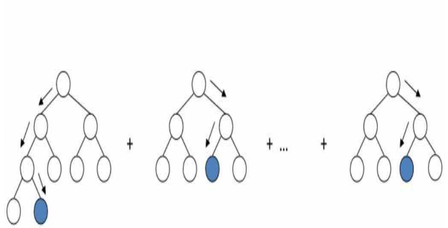

- Grubbs
- Isolation Forest
- GBDT
- 逻辑策略

工程方案

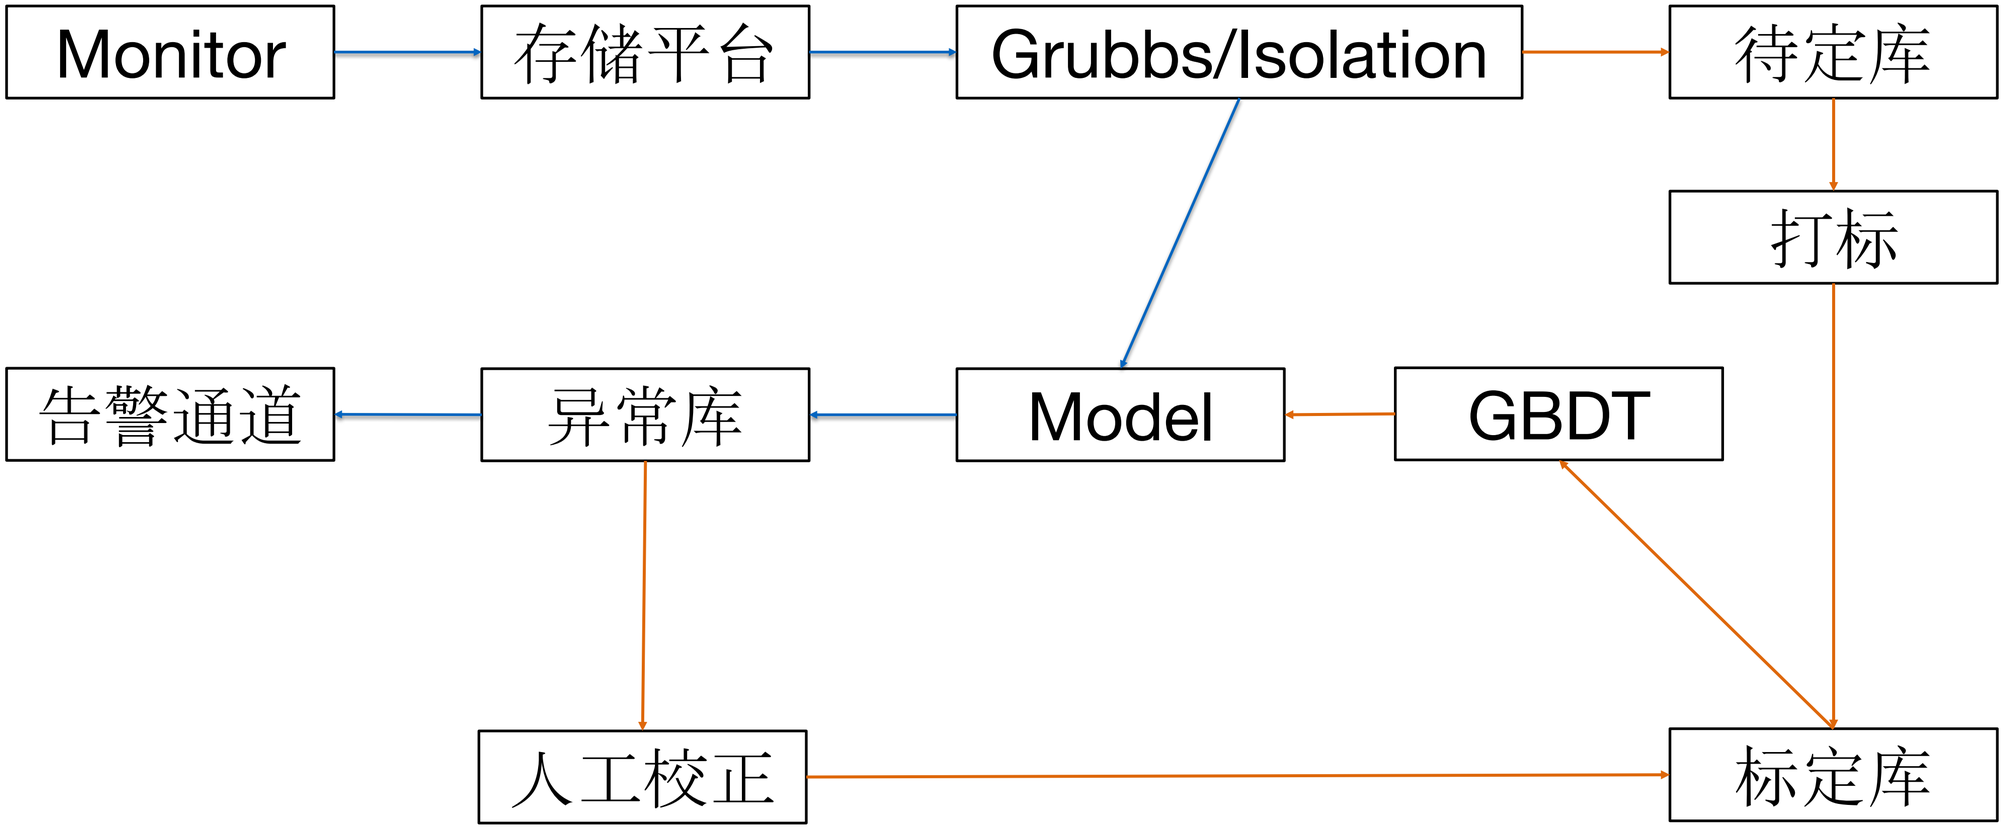
Monitor
存储平台
Grubbs/Isolation
待定库
打标
告警通道
异常库
Model
GBDT
人工校正
标定库

数据与计算“坑”

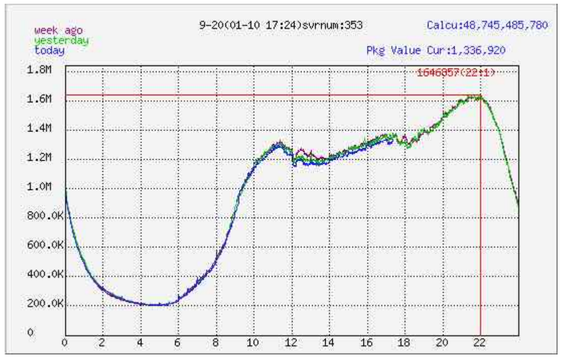

1.数据缺失
2.“零”值
3.数据变更

1.计算延时
2.“雪崩”

特征“坑”

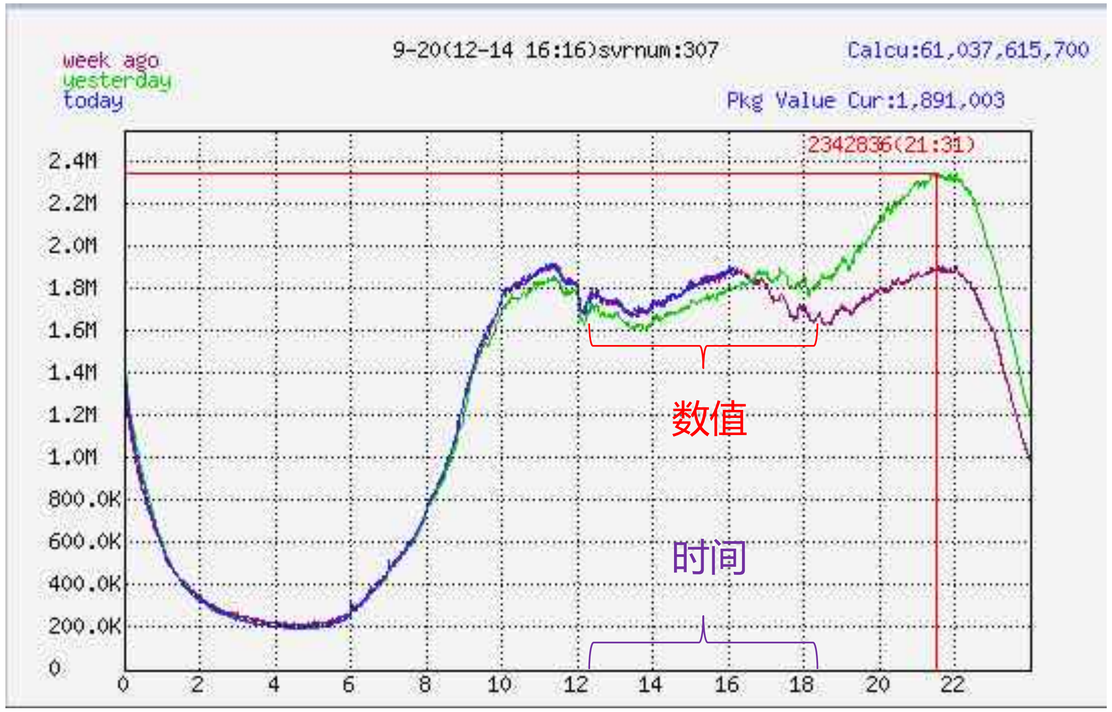
week ago
yesterday
today
9-20(12-14 16:16)svrnum:307
Calcu:61,037,615,700
Pkg Value Cur:1,891,003
2342836(21:31)
2.4M
2.2M
2.0M
1.8M
1.6M
1.4M
1.2M
1.0M
800.0K
600.0K
400.0K
200.0K
0
0
2
4
6
8
10
12
14
16
18
20
22
数值
时间

时间与值对应

系统-展示

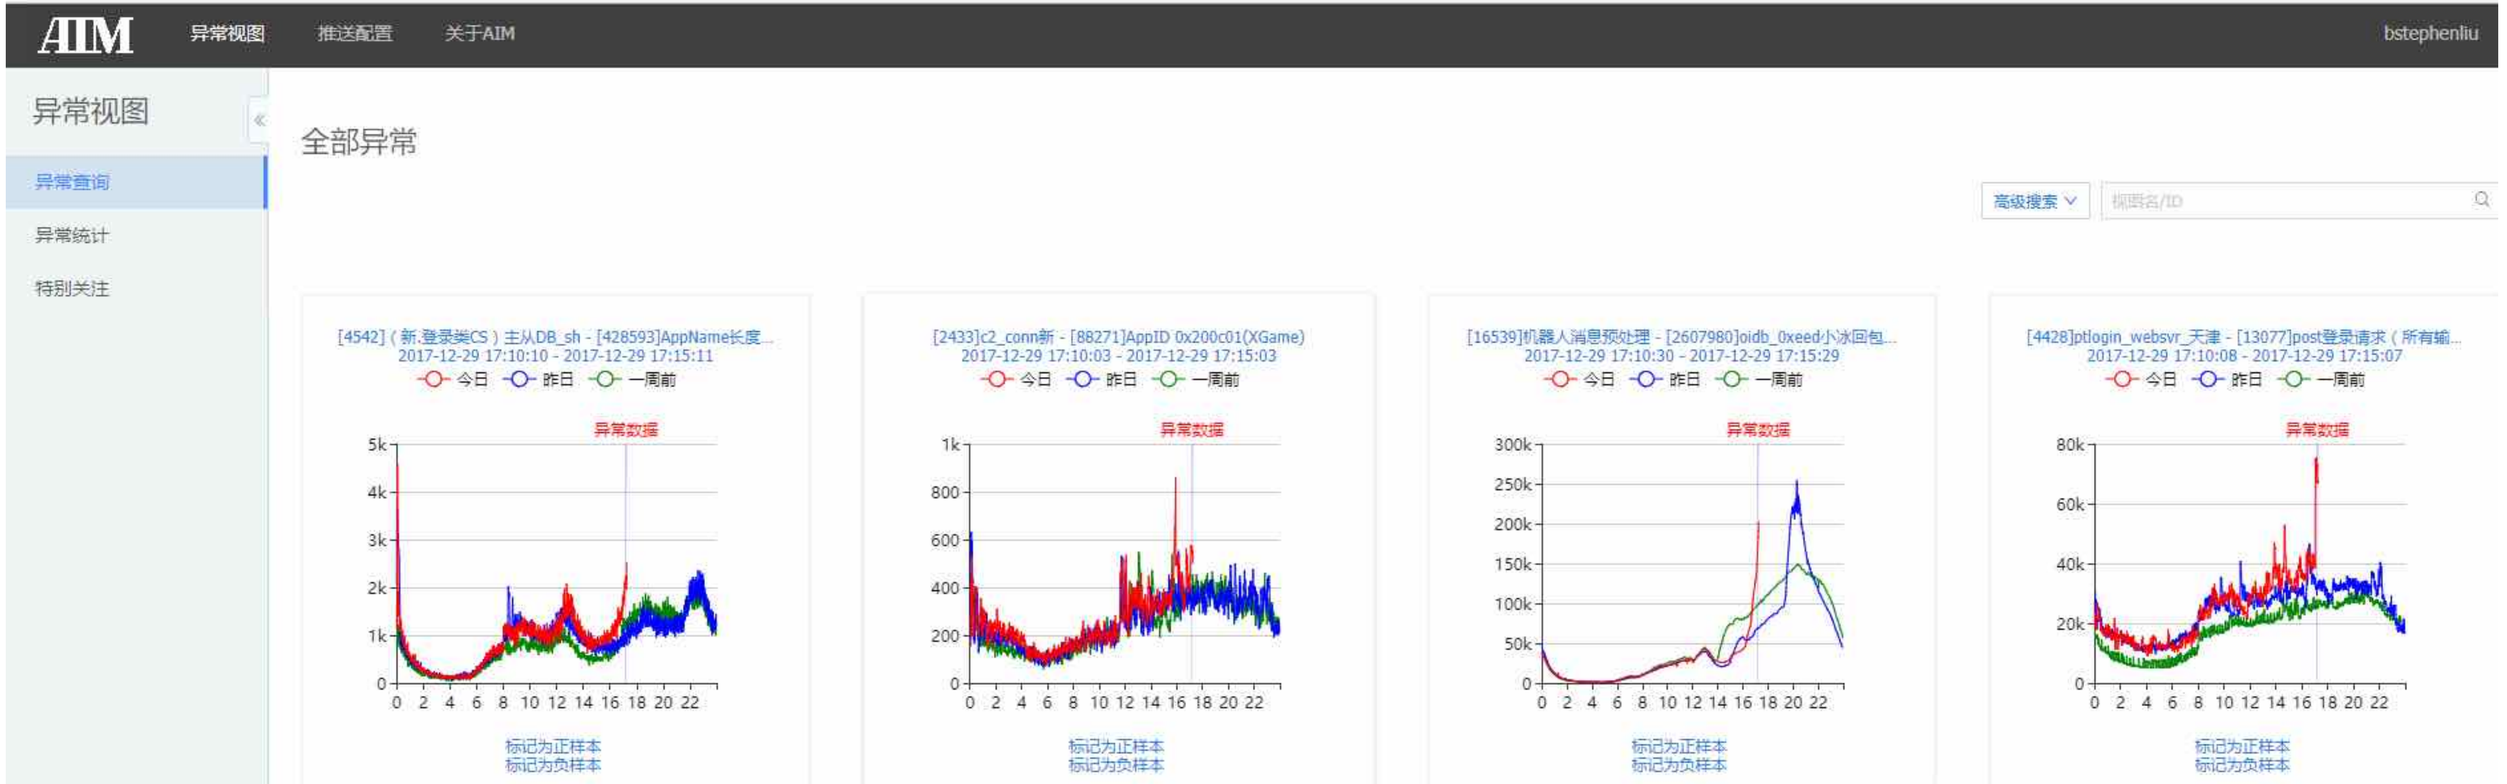
AIM
异常视图
推送配置
关于AIM
bstephenliu
异常视图
异常查询
异常统计
特别关注
全部异常
高级搜索
模糊名/ID
[4542]（新.登录类CS）主从DB_sh - [428593]AppName长度...
2017-12-29 17:10:10 - 2017-12-29 17:15:11
今日 昨日 一周前
异常数据
标记为正样本
标记为负样本
[2433]c2_conn新 - [88271]AppID 0x200c01(XGame)
2017-12-29 17:10:03 - 2017-12-29 17:15:03
今日 昨日 一周前
异常数据
标记为正样本
标记为负样本
[16539]机器人消息预处理 - [2607980]oidb_0xeed小冰回包...
2017-12-29 17:10:30 - 2017-12-29 17:15:29
今日 昨日 一周前
异常数据
标记为正样本
标记为负样本
[4428]ptlogin_websvr_天津 - [13077]post登录请求（所有输...
2017-12-29 17:10:08 - 2017-12-29 17:15:07
今日 昨日 一周前
异常数据
标记为正样本
标记为负样本

系统-接入


AIM
异常视图
推送配置
关于AIM
推送配置
视图订阅
属性屏蔽
新增订阅
1 配置群信息
2 选择模块/视图
订阅名：
请为本次订阅起个名字吧！
推送群号：
请输入接收告警的QQ群号！
当前用户QQ号为 1064375898！请确保该QQ在该群中为管理员！如需更改请点击此处
负责人：
bstephenliu

系统-输出

智能检测

【智能告警】视图:【udpconn_天津移动】，属性:【sched--老重定向逻辑忽视ISP要求返回本IDC】在时间点：2018-01-09 09:06发生异常。
http://monitor.server.com/link/graph/viewid:5654/pointer:282415/compare

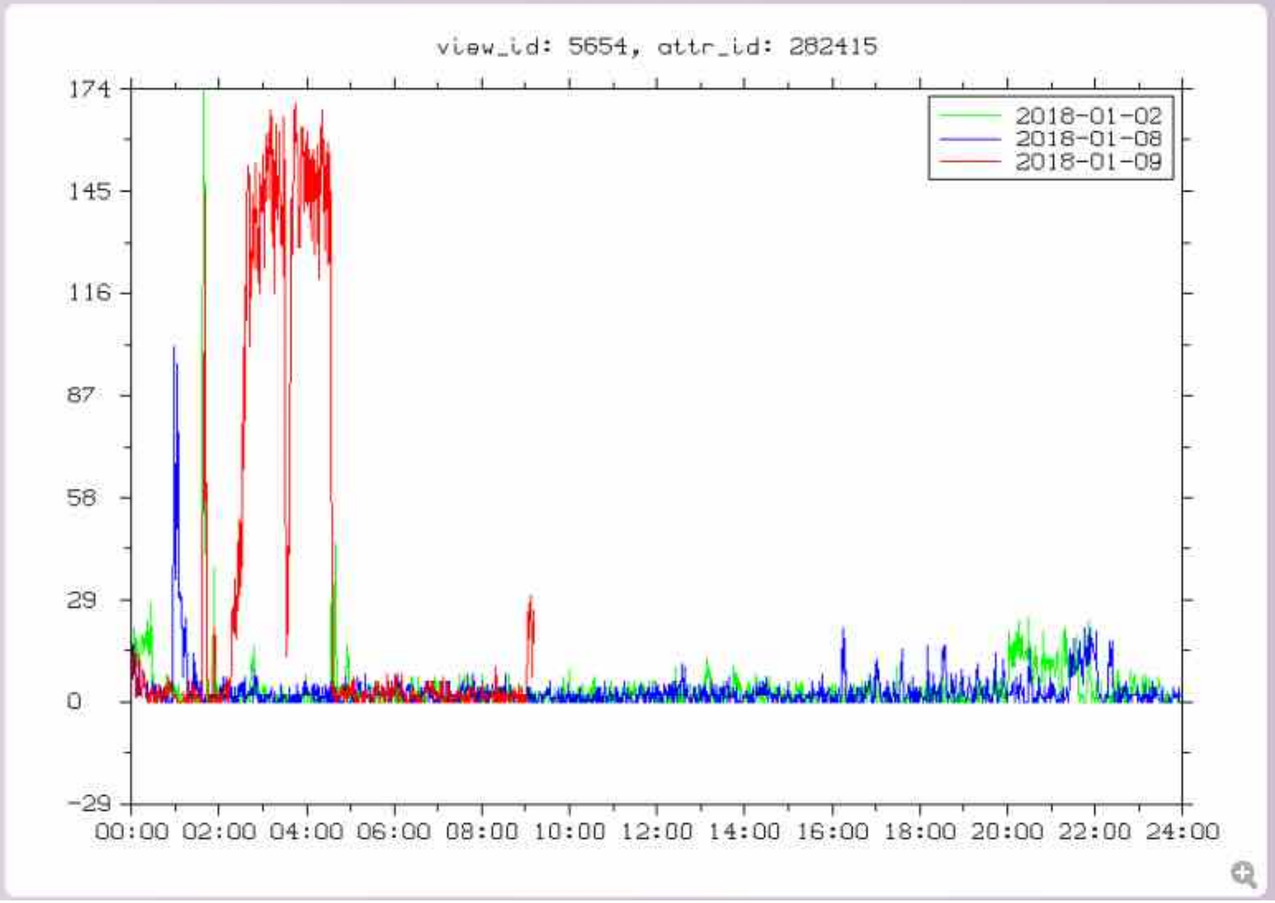

TABLE OF CONTENTES

下一步：关联分析和根因分析

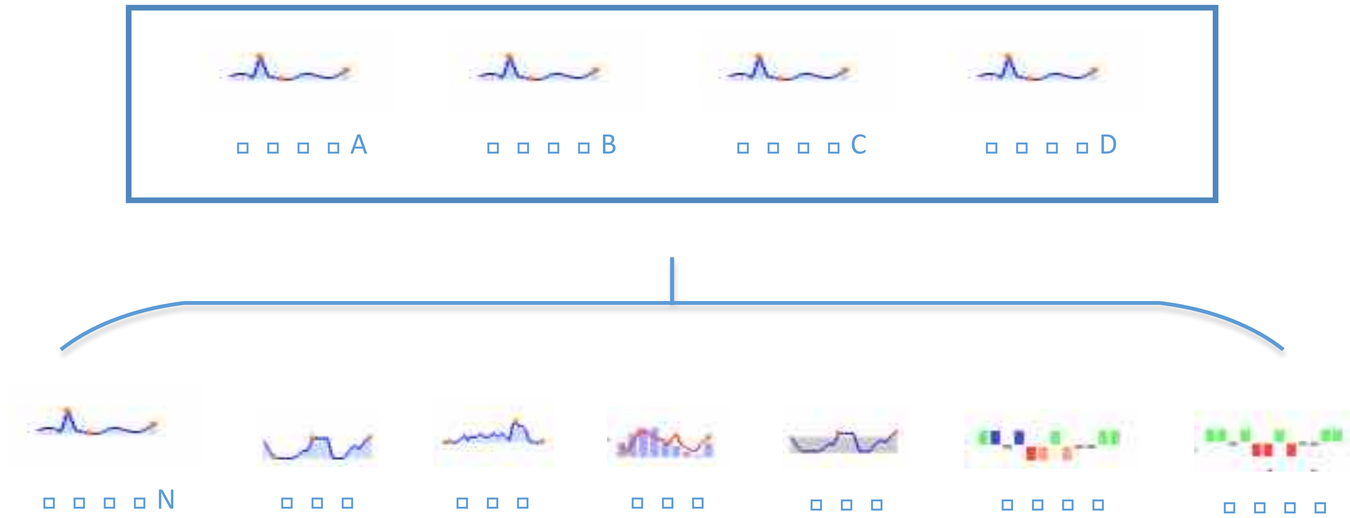

关联分析

1. 时间关联
2. 空间关联
3. 逻辑关联

根因分析

1. 时间、空间与逻辑关联的因、果分析
2. “自愈”

Thanks!